5205-project2

项目流程

4.1 明确研究对象

1. market：哪个交易市场（**美股**，港股，中国A股，...，因为这些交易市场的指标和市场表现都不太一样，我们要确定我们研究什么）
2. asset：①只研究一种；②选择一种，另外一种作为投资基准
    - 股票：pros(多数量化金融项目都是以股票，这会是很大众的选择)；cons(股票数据量太大，在控制时空复杂度的前提下，如何选股票市场、选哪几只股票都十分影响模型的准确性)；适合策略：个股动量、收益预测、多空选股
    - ETF：pros(数据量小，数据容易获得)；cons(对ETF的研究相对小众，没有股票那么广泛)；适合策略：市场择时、趋势跟踪、资产配置
3. calendar+currency：

- calendar：如何处理周末和市场休市日？休市日？
- currency：基准货币？交易资产用什么货币计价？所有收益是否统一用一种货币计算？跨市场？（涉及汇率换算，不考虑也行）

```
e.g.: 假如美股或美国上市 ETF，使用 USD 即可
```

4. frequency+trading time: 比较复杂，认真讨论

- Frequency：多久产生一次交易决策?
- Trading Time：什么时候观察信号，什么时候实际成交？（intraday分钟级/**daily日度**/monthly月度）

```
e.g.:一个daily strategy的例子:
第 t 天收盘计算信号 -> 第 t+1 天开盘执行交易 -> 持仓期间计算收益
```

5. data source

商讨结果：

- market+assets: US-SPY ETF
- calendar: 导入包 `pandas_market_calendars`
- time zone: 直接选定美国东部 `America/New York`
- frequency: daily
- trading time: daliy，第t个交易日收盘时刻记录市场生成预测**决策**，第t+1个交易日开盘时**执行**交易预测，第t+2个交易日开盘重新调仓
- data source: `yfinance`（Yahoo Finance）,分红已经被内置处理好 `auto_adjust=True`

4.2 特征工程

1. feature+labels：明确我们在市场大盘中选择哪些数据指标作为features。feature的选择只应该是公众渠道可以获取的直接信息，无需二次人工构建。
2. data scaling+cleaning：标准化；处理缺失值、错漏值等。

商讨结果：

- labels：**Next open-to-open return**，考虑开盘价A^{open}，模型预测labels设定为$y_t = \frac{A^{open}_{t+2}}{A^{open}_{t+1}} - 1$
- features：
  - 1d/5d/20d 收益率(momentum,return)：

    例如5日 Momentum：

    $$Mom_{5,t} = \frac{A^{close}_t}{A^{close}_{t-5}} - 1$$

    20日 Momentum：

    $$Mom_{20,t} = \frac{A^{close}_t}{A^{close}_{t-20}} - 1$$

  - 5d/20d/60d 波动率(volatility)

    4.2 怎么计算?

    首先计算每日收盘到收盘的收益率：

    $$r_t = \frac{A^{close}_t}{A^{close}_{t-1}} - 1$$

    然后计算过去20个交易日的标准差：

    $$Vol_{20,t} = \mathrm{Std}(r_{t-19}, \ldots, r_t)$$

    如果想得到年化波动率：

    $$Vol^{ann}_{20,t} = Vol_{20,t}\sqrt{252}$$

    对于 Regression，使用日频还是年化波动率都可以，但必须保持单位一致，并在报告中说明。

- 5d/20d趋势(trend)：

  Moving Average（移动平均线）就是过去一段时间价格的平均值。

  例如：

  $$MA_{5,t} = \frac{1}{5}\sum_{i=0}^{4} A_{t-i}^{close}$$

  $$MA_{20,t} = \frac{1}{20}\sum_{i=0}^{19} A_{t-i}^{close}$$

  我们可以构造：

  $$MA_Gap_t = \frac{MA_{5,t}}{MA_{20,t}} - 1$$

  它衡量短期价格趋势相对于中期趋势的强弱。

  如果：

  $$MA_{5,t} > MA_{20,t}$$

  说明近期平均价格高于较长期平均价格。

- vix指数：直接从原数据集中获取
- RSI：

  1. RSI 核心公式

  $$\boxed{RSI = 100 - \frac{100}{1 + RS}}$$

  其中：

  $$RS = \frac{\text{Average Gain}}{\text{Average Loss}}$$

  - **Average Gain**：平均上涨幅度
  - **Average Loss**：平均下跌幅度（取正值）
  - **RS**：平均涨幅与平均跌幅的比值

- 相对成交量（relative volume）：

  我不建议直接使用：

  $$Volume_t = 75,000,000$$

  因为成交量的绝对水平可能随着时间变化，难以直接比较不同历史时期。

  更合理的是构造 **Relative Volume（相对成交量）**：

  $$RVOL_t = \frac{Volume_t}{\frac{1}{20}\sum_{i=0}^{19} Volume_{t-i}}$$

  例如：

  - 今天成交量：1亿份。
  - 过去20日平均成交量：5,000万份。

  那么：

  $$RVOL_t = 2$$

  说明今天的成交量是近期平均水平的两倍。

- 当日价格波动（intra-day return）：

  可以定义：

  $$Intraday_t = \frac{Close_t}{Open_t} - 1$$

  它反映 SPY 当天从开盘到收盘的价格变化。

  例如：

  - 今日开盘：500美元。
  - 今日收盘：505美元。

  那么：

  $$Intraday_t = 1\%$$

- data scaling: 试candidate models而定
- data cleaning: outliers异常值保留（真实市场）； missing values缺失值删除。

4.3 明确benchmark

可选的方向：

- buy and hold
- naive forecasting baseline：simplest

商讨结果：

- buy-and-hold必选
- naive baseline：选择historical mean forecast，具体选择过去d天看实际

4.4 candidate models

选择模型，指定Overfitting control（主要是regularization，提及即可）

商讨结果：

- Random forest
- OLS regression
- Lasso regression
- Ridge regression

4.5 data splitting

train/val/test

> `tips:`
> 需要防止时间线上发生`Info leakage`，这在量化金融中严禁发生（即用未来数据预测历史数据，在划分数据时需要严格注意）

商讨结果：

- data period_splitting：year 2010-2025
  - 需要采样2009年最后60d的数据: warm-up period
  - training period: year 2010-2017
  - validation period: year 2018-2021(expanding window，即4.7部分的forward validation方法)
  - testing period: year 2022-2025
- 数据接口设置（交付格式）：

日期	`year`	所属年份
日期	`decision_date`	生成预测信号的日期
日期	`execution_date`	下一交易日开盘执行日期
日期	`holding_end_date`	再下一交易日开盘日期
Feature	11个 Feature 列	模型输入
Label / Backtest	`target_return`	训练标签和实际持仓收益

确定！每个 CSV 文件直接以年份命名：

`2010.csv`、`2011.csv`、……、`2025.csv`

所有文件统一使用以下 **16列**，列名和顺序保持一致。

序号	Column Name	含义
1	`year`	所属年份
2	`decision_date`	生成预测信号的日期
3	`execution_date`	下一交易日开盘执行日期
4	`holding_end_date`	再下一交易日开盘日期
5	`return_1d`	1日收益率
6	`momentum_5d`	5日动量
7	`momentum_20d`	20日动量
8	`volatility_5d`	5日波动率
9	`volatility_20d`	20日波动率
10	`volatility_60d`	60日波动率
11	`ma_gap_5_20`	5/20日移动平均线差异
12	`vix`	VIX指数
13	`rsi_14`	14日RSI
14	`relative_volume_20d`	20日相对成交量
15	`intraday_return`	当日开盘至收盘收益率
16	`target_return`	下一持仓期 SPY Total Return（Label）

4.6 training

- Reproducibility（保证整个流程的可复现性）
- record grids（params, seeds,...）

4.7 validation

- 推荐选择前向验证（forward validation）：

```
时间轴 ──────────────────────────────────────────→
  训练 [2017-2019] → 测试 [2020]
  训练 [2017-2020] → 测试 [2021]
  训练 [2017-2021] → 测试 [2022]
  训练 [2017-2022] → 测试 [2023]
  训练 [2017-2023] → 测试 [2024]
```

4.8 strategy

- 模型预测结果->positions(仓位)：如何根据我们的结果去指定市场中的买卖策略
- 交易成本：是否考虑交易成本，这或许与frequency的选择有关
- 风险控制：考虑哪些指标被选作策略时的risk，可以与特征工程时选择的features相同或不同；将这些risk指标进行数学组合，应用于我们的策略，使之更加严谨

商讨结果：

- 仓位规则(proportional strategy)：

  $w_{t+1} = \min\left(1, \max\left(0, \frac{\hat{y}_t}{k}\right)\right)$

  $k \in \{0.0025, 0.005, 0.01\}$

- 风险控制：

  $\delta \in \{0, 0.05, 0.10\}$:

  我们设定：

  $$\delta = 0.05$$

  比较模型目标仓位与成交前实际仓位：

  $$\Delta w_t = w_t^{target} - w_t^{current}$$

  最终执行仓位：

  $$\boxed{w_t^{final} = \begin{cases} w_t^{current}, & |\Delta w_t| < 0.05 \\ w_t^{target}, & |\Delta w_t| \geq 0.05 \end{cases}}$$

  可能风险控制还考虑加入市场波动率?

- 交易成本设置为0，不考虑

4.9 evaluate

确定metrics，适当绘图

商讨结果：

1. Prediction Performance（预测能力）

Metric	作用	推荐程度
MSE	衡量预测收益率的误差	必选
OOS R^2	衡量模型是否优于简单预测基准	必选
MAE	衡量平均预测误差	可选

2. Trading Performance（交易表现）

Metric	作用	推荐程度
Annualized Return	年化收益率	必选
Annualized Volatility	年化波动率	必选
Sharpe Ratio	风险调整后的收益	必选
Maximum Drawdown	最大回撤，衡量最大历史跌幅	推荐

这部分需要和 **SPY Buy-and-Hold** 比较，并扣除交易成本。

3. Trading Efficiency（交易效率）

Metric	作用	推荐程度
Turnover	衡量交易频繁程度	推荐

与buy-and-hold和baseline比较：

Prediction Performance：5个预测方法

Historical Mean、OLS、Ridge、LASSO、Random Forest。

指标：MSE、OOS R^2、MAE。

Trading Performance & Efficiency：6个交易策略

Historical Mean Strategy、OLS Strategy、Ridge Strategy、LASSO Strategy、Random Forest Strategy、SPY Buy-and-Hold。

指标：Annualized Return、Annualized Volatility、Sharpe Ratio、Maximum Drawdown、Turnover。

分工计划



Group A: Yan Yi & Lu Yue

Group B: Li Linxi & Cai Yuxuan